神經網路

ANN
(Artificial) neural network

NN
neural network

生物神經系統的結構，神經元(Neuron)之間互相連結，由外部神經元接收信號，再層層傳導至其他神經元，最後作出反應的過程

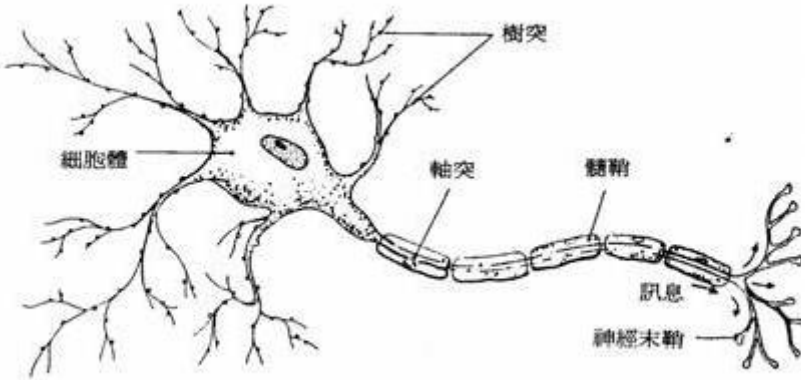

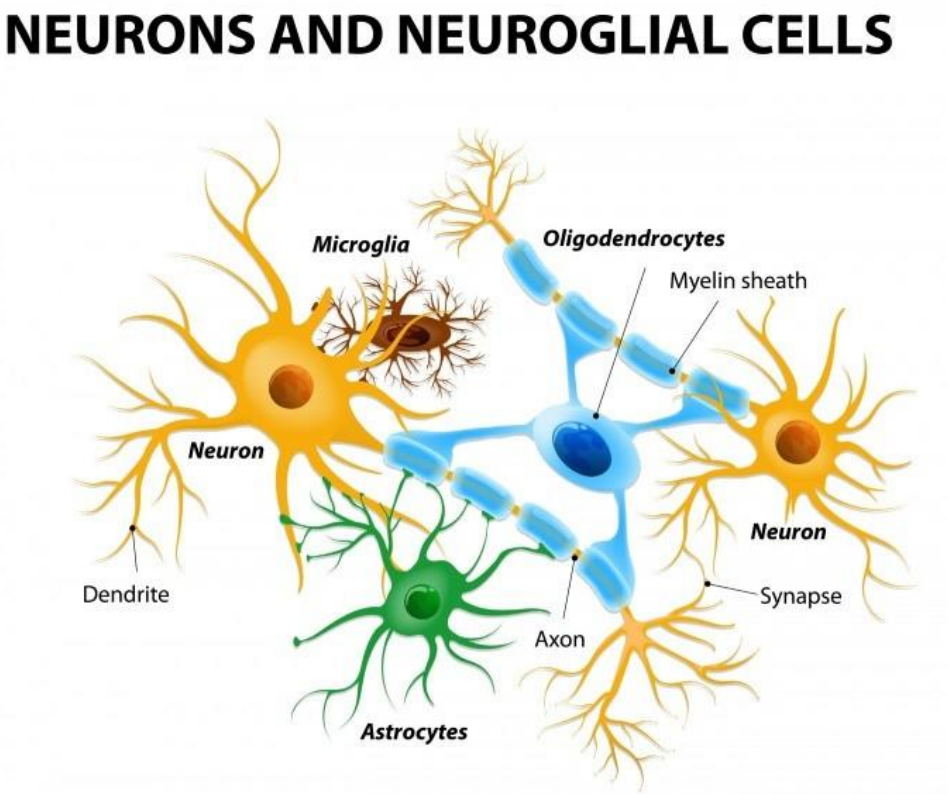

https://ithelp.ithome.com.tw/articles/10191528

AI 第一個黃金年代：1956 - 1974

1956年達特茅斯會議：AI的誕生

1956年達特矛斯會議的組織者是馬文·明斯基，約翰·麥卡錫和另兩位資深科學家克勞德·香農以及Nathan Rochester。

會議提出的斷言之一是「**學習或者智能的任何其他特性的每一個方面都應能被精確地加以描述，使得機器可以對其進行模擬**。」

與會者包括Ray Solomonoff，Oliver Selfridg，Trenchard More，Arthur Samuel，艾倫·紐厄爾和赫伯特·西蒙

麥卡錫則說服與會者接受「人工智慧」一詞作為本領域的名稱。

1956年達特矛斯會議上AI的名稱和任務得以確定，同時出現了最初的成就和最早的一批研究者，因此這一事件被廣泛承認為AI誕生的標誌。

Frank Rosenblatt (July 11, 1928 – July 11, 1971)

感知器是神經網絡的一種形式，由Frank Rosenblatt於1958年提出。
與多數AI研究者一樣，他對這一發明的潛力非常樂觀，預言說「感知器最終將能夠學習，作出決策和翻譯語言」。
整個六十年代裡這一方向的研究工作都很活躍。

https://en.wikipedia.org/wiki/Perceptrons_(book)

1969年Minsky和Papert出版了著作《感知器》

書中暗示感知器具有嚴重局限，而Frank Rosenblatt的預言過於誇張。

這本書的影響是破壞性的：聯結主義的研究因此停滯了十年。後來新一代研究者使這一領域獲得重生，並使其成為人工智慧中的重要部分；遺憾的是Rosenblatt沒能看到這些，他在《感知器》問世後不久即因遊船事故去世

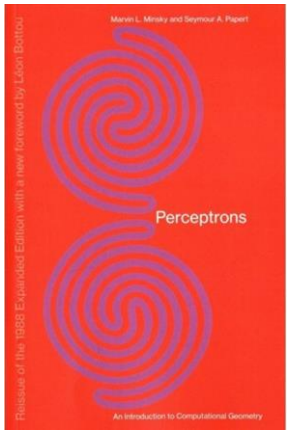

第一次AI低谷：1974 - 1980

Artificial neural network(ANN)

模型化➔類神經網路

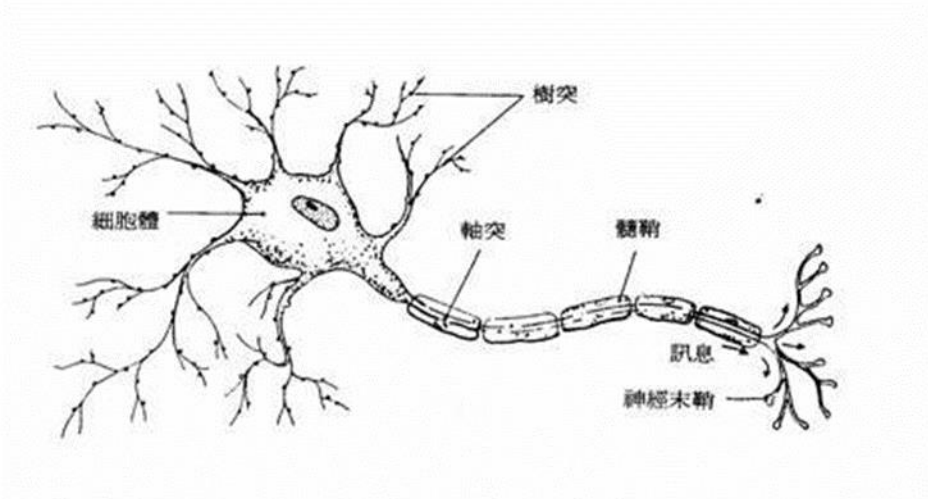

$$z = (w_1x_1 + w_2x_2 + \cdots + w_nx_n) + b = \mathbf{w} \cdot \mathbf{x} + b$$

感知機 perceptron模型

模型參數:W(權重) b(bias偏差值)

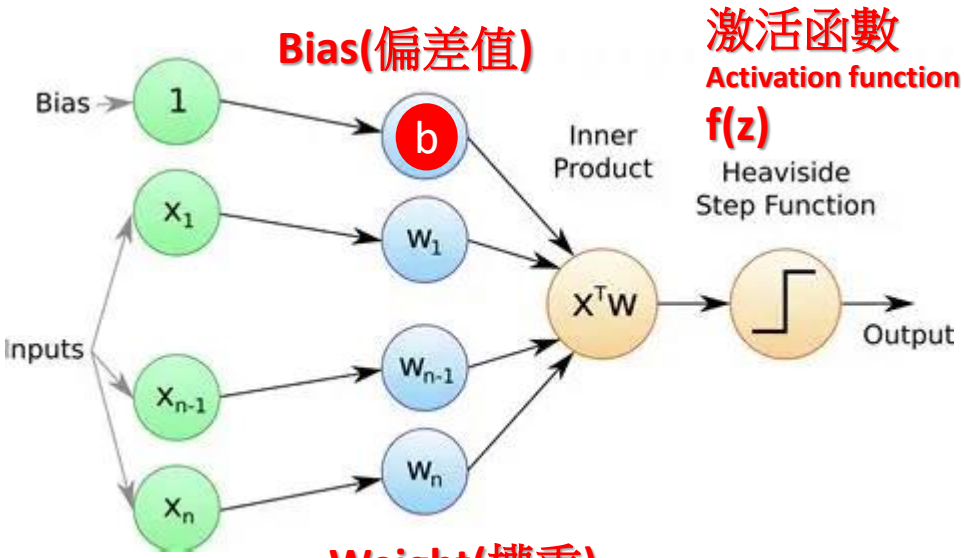

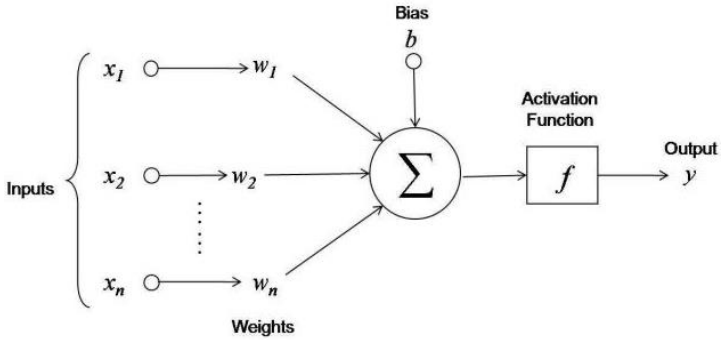

激活函數:Activation function

Step Function階梯函數
(缺點:不可微)

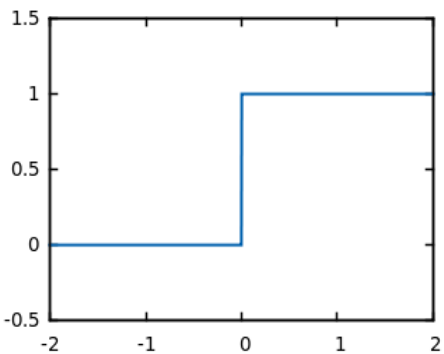

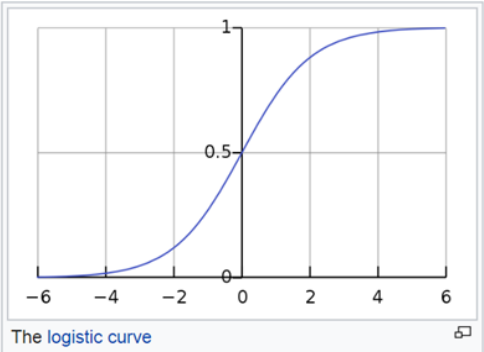

Leaky ReLU

$$\max(0.1x, x)$$

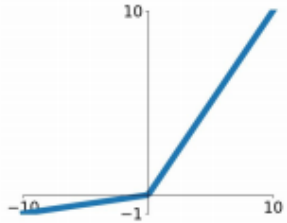

tanh

$$\tanh(x)$$

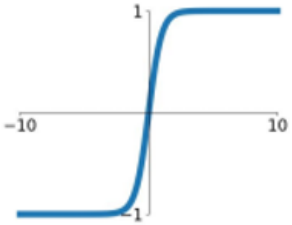

Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ReLU

$$\max(0, x)$$

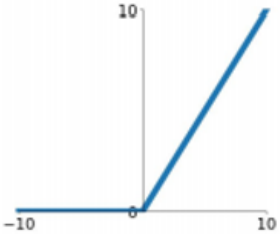

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

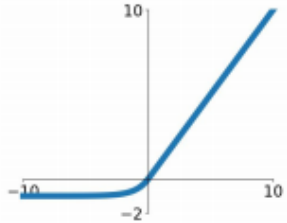

Sigmoid function

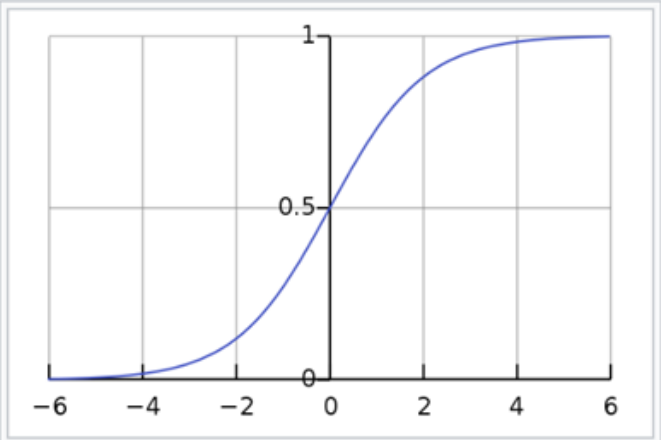

The logistic curve

- **公式：** $f(x) = \frac{1}{1+e^{-x}}$
- **圖形：** 一條將輸入壓縮到 (0, 1) 之間的 "S" 型曲線。
- **優點：**
  1. **輸出範圍 (0, 1)：** 輸出值可以被解釋為機率，非常適用於**二元分類 (Binary Classification)** 問題的**輸出層**。
  2. **平滑：** 函數平滑且可微，易於計算梯度。
- **缺點：**
  1. **梯度消失 (Vanishing Gradients)：** 當輸入 x 非常大（> 4）或非常小（< -4）時，Sigmoid 函數的導數（梯度）趨近於 0。在反向傳播 (Backpropagation) 中，梯度會逐層相乘，如果多層都使用 Sigmoid，梯度會迅速縮小，導致靠近輸入層的權重幾乎無法更新，使網絡學習緩慢甚至停滯。
  2. **非零中心 (Not Zero-centered)：** 輸出恆為正 (0, 1)。這會導致在反向傳播時，權重的梯度要嘛同為正、要嘛同為負，導致權重更新時呈 "Z" 字形（zigzag）下降，收斂速度變慢。

Tanh (雙曲正切函數)

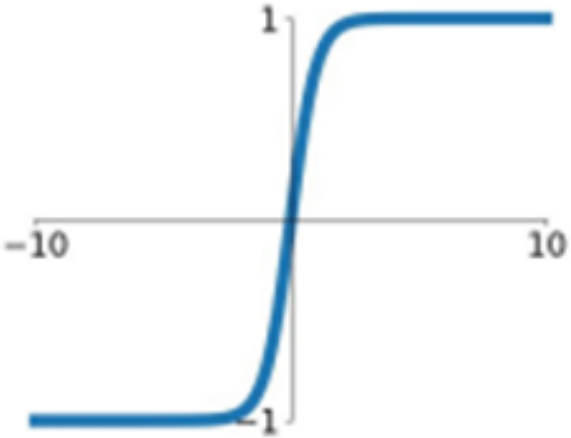

- **公式：** $f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
  - （它其實是縮放後的 Sigmoid：$\tanh(x) = 2 \cdot \text{Sigmoid}(2x) - 1$）
- **圖形：** 類似 Sigmoid，但範圍被壓縮到 (-1, 1) 之間。
- **優點：**
  1. **零中心 (Zero-centered)：** 輸出範圍為 (-1, 1)，均值為 0。這緩解了 Sigmoid 的非零中心問題，通常能讓模型收斂更快。
- **缺點：**
  1. **梯度消失 (Vanishing Gradients)：** 仍然存在梯度消失問題。當輸入值 x 很大或很小時，梯度同樣趨近於 0。

ReLU (Rectified Linear Unit) 修正線性單元)

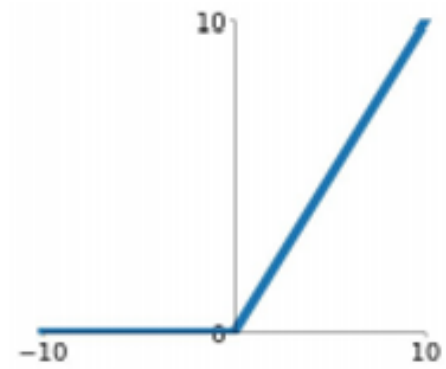

- ✓ 目前最常用、表現通常最好的預設選項。
- ✓ 它的收斂速度快且計算簡單。

- **公式：** $f(x) = \max(0, x)$
- **圖形：** 當 $x \leq 0$ 時，輸出為 0；當 $x > 0$ 時，輸出為 x（一條斜率為 1 的直線）。
- **優點：**
  1. **解決梯度消失（在正區間）：** 當 $x > 0$ 時，梯度恆為 1。這極大地緩解了梯度消失問題，讓深度網絡的訓練成為可能。
  2. **計算效率高：** 僅涉及一個簡單的 $\max$ 運算，比 Sigmoid / Tanh 的指數運算快得多。
  3. **引入稀疏性 (Sparsity)：** 它會使一部分神經元的輸出為 0，這使得網絡變得稀疏，降低了參數的依賴性，可能有助於防止過擬合。
- **缺點：**
  1. **Dying ReLU (ReLU神經元死亡)：** 當一個神經元的輸入 z 在訓練過程中恆為負時，它的輸出將永遠是 0，其梯度也永遠是 0。這意味著這個神經元將永遠無法被更新（死亡）。這通常發生在學習率 (learning rate) 設置過高時。
  2. **非零中心 (Not Zero-centered)：** 輸出恆為非負（≥ 0）。

類神經網路起手式:感知機

Solving XOR with a single Perceptron

完成OR gate, NOR及NAND gate的實作

真值表[邏輯閘]

	AND	OR	NAND	NOR
輸入	輸出	輸出	輸出	輸出
0 0	0	0	1	1
0 1	0	1	1	0
1 0	0	1	1	0
1 1	1	1	0	0
符號				

感知機模型(MODEL)

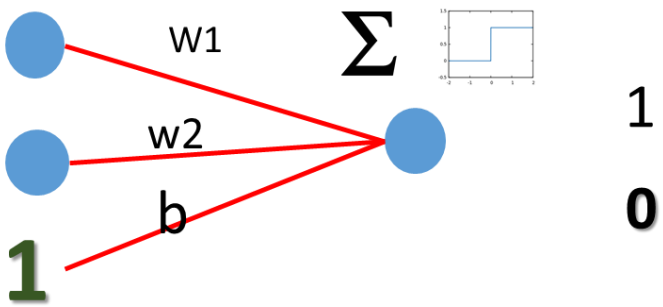

感知機 perceptron模型
模型參數:W(權重) b(bias偏差值)

1 0 1 0

1 1 0 0

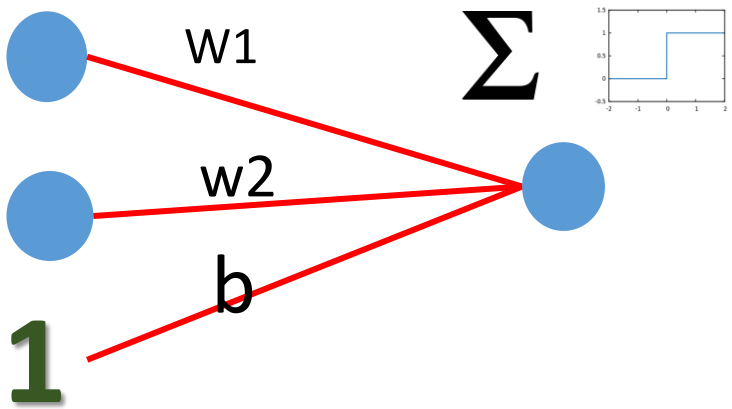

1

0

模型參數(Parameters): W1=?, W2=?, b=?

	AND
輸入	輸出
0 0	0
0 1	0
1 0	0
1 1	1
符號	

模型參數(Parameters)設定成底下值就可以表現AND邏輯閘的行為

W1 = 0.5

W2 = 0.5

b = -0.7

那裏有 Learning ??

真值表[邏輯閘]

無法單純使用
感知機 perceptron模型
來表示其行為

解的出
來嗎??

	AND	OR	NAND	NOR	XOR	XNOR
輸入	輸出	輸出	輸出	輸出	輸出	輸出
0 0	0	0	1	1	0	1
0 1	0	1	1	0	1	0
1 0	0	1	1	0	1	0
1 1	1	1	0	0	0	1
符號						

無法單純使用
感知機 perceptron模型
來表示其行為

但加入中間層可以表現
XOR及XNOR邏輯閘的行為

XOR	XNOR
輸出	輸出
0	1
1	0
1	0
0	1

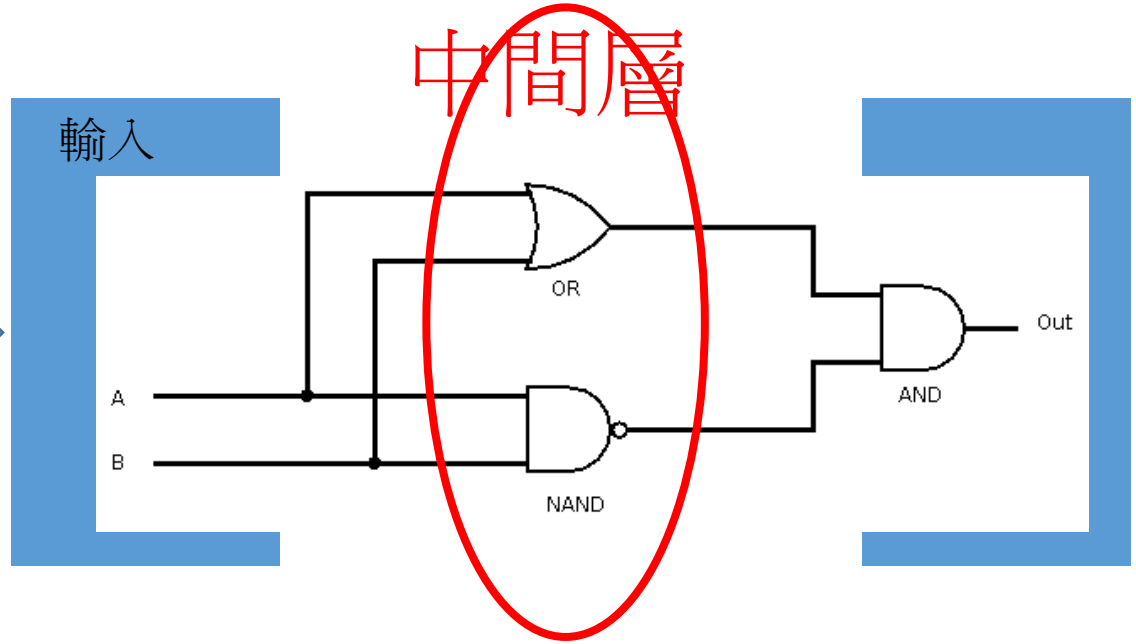

多層感知機 Multilayer perceptron, MLP

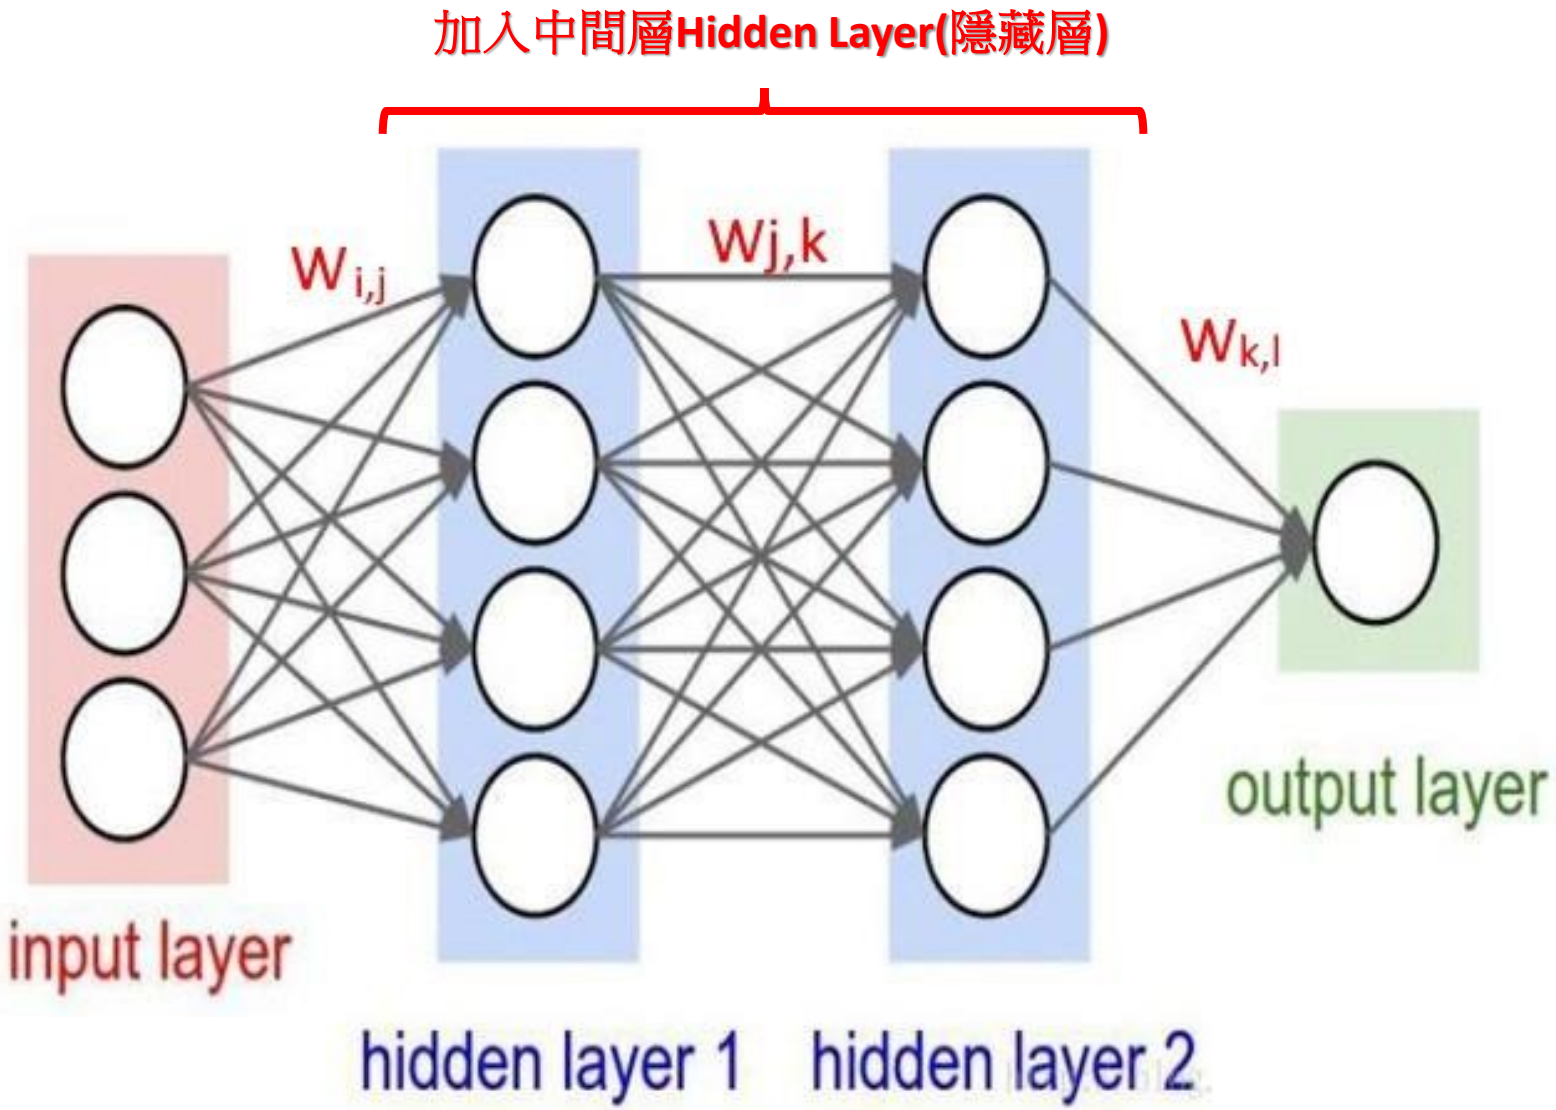

線性可分(linearly separable)

AND		
I_1	I_2	out
0	0	0
0	1	0
1	0	0
1	1	1

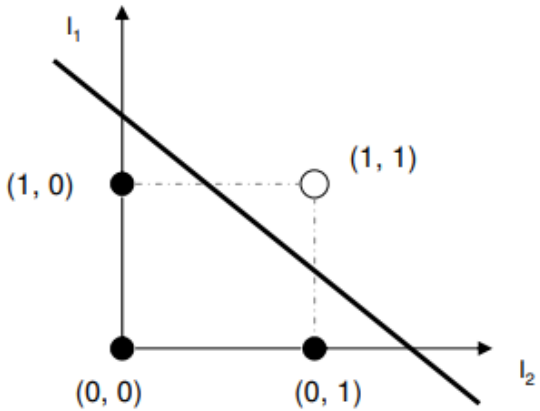

OR		
I_1	I_2	out
0	0	0
0	1	1
1	0	1
1	1	1

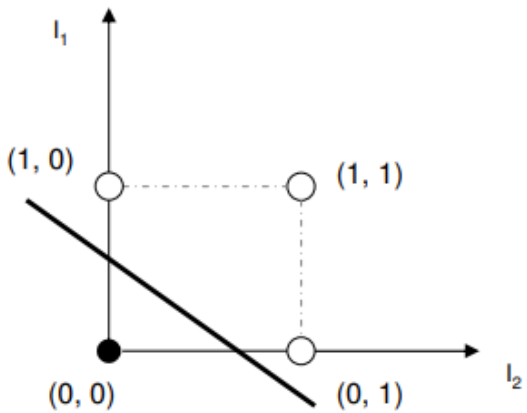

線性不可分(linearly **NON**separable)

XOR		
I_1	I_2	out
0	0	0
0	1	1
1	0	1
1	1	0

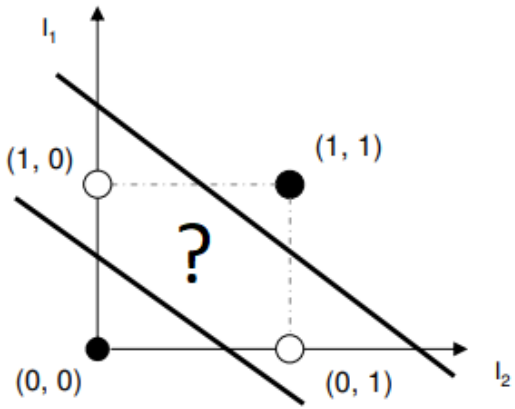

具有學習能力的神經網路(1)

步驟一:將Weight(權重)與Bias(偏權值)隨機設定(例如全為0)

有不同方式設定W b

計算出模型結果值(預測值)

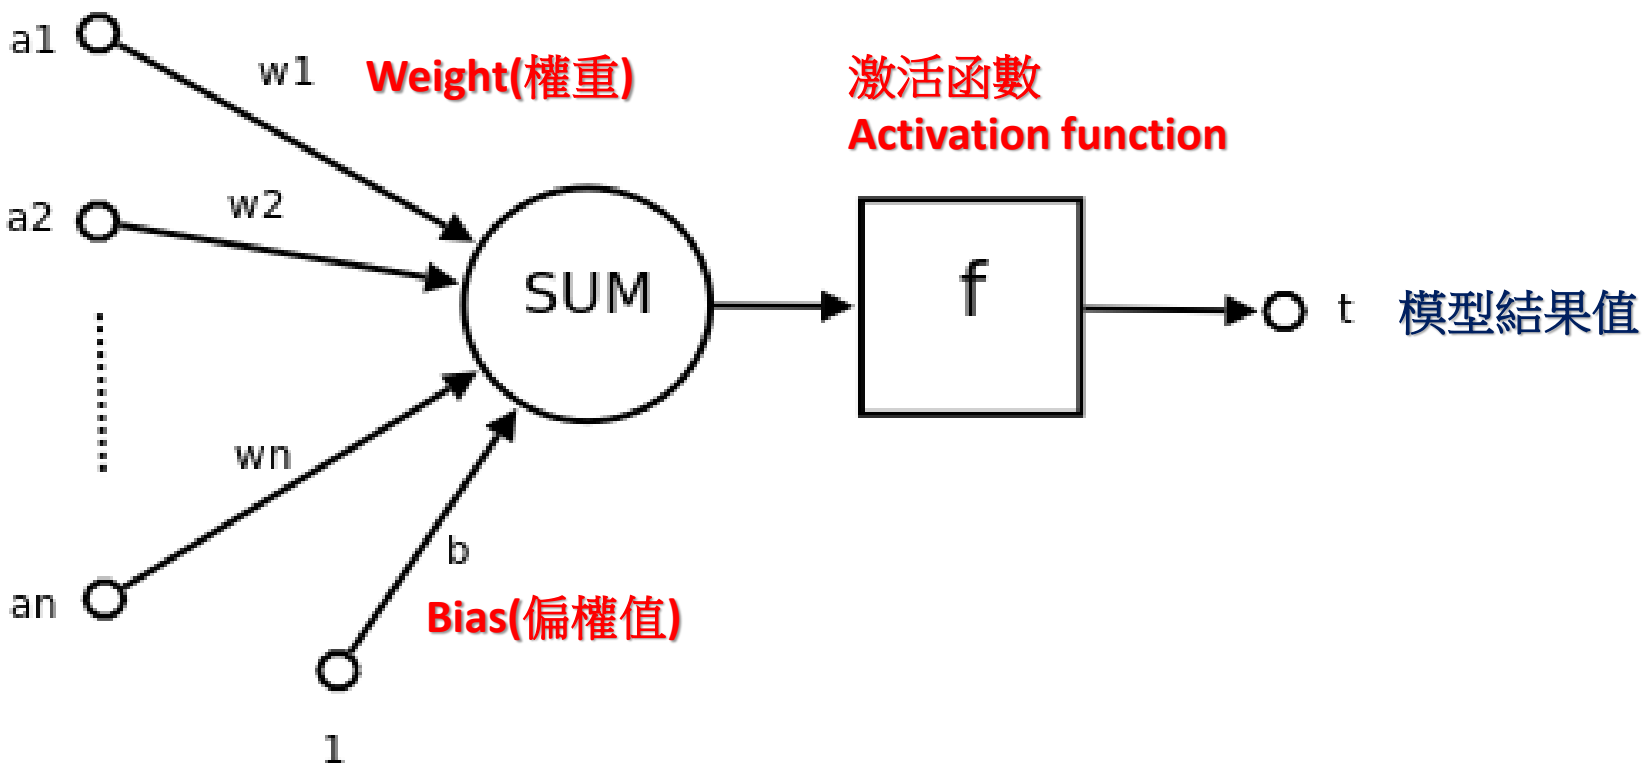

具有學習能力的神經網路(2)

步驟二:設計並計算出誤差(error)

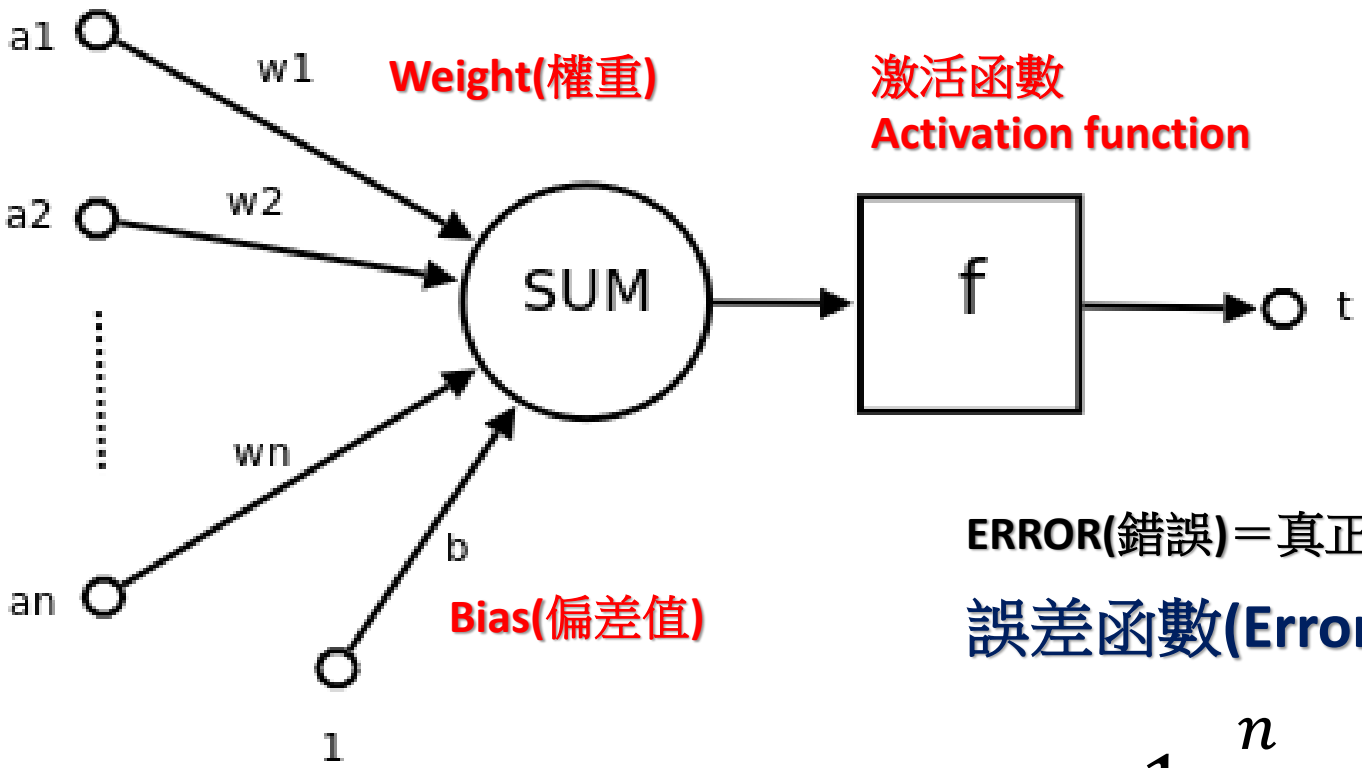

ERROR(錯誤)＝真正的值(t) - 預測值(y)

誤差函數(Error function)

$$E = \frac{1}{2}\sum_{i=1}^{n}(y_i - t_i)^2$$

Error Function誤差函數
Loss Function損失函數
Cost Function 成本函數

具有學習能力的神經網路(3)

η = 學習率(learning rate)
正數, 約取0.1~0.3

步驟三:定義Weight(權重)與Bias(偏權值)的更新策略

Update the weights and bias

梯度下降(負號)法

W(新的)=W(前一回) – η*Gradient(梯度)

W(新的)=W(前一回) - △W(誤差變動)
B(新的)=b(前一回) - △b(誤差變動)

Gradient(梯度)

$$\Delta \mathbf{w} = \eta \boxed{\mathbf{X}^T \cdot \left(\hat{\mathbf{y}} - \mathbf{y}\right)}$$

$$\Delta b = \eta \boxed{\left(\hat{\mathbf{y}} - \mathbf{y}\right)}$$

學習規則

$$\frac{\partial Error}{\partial w}, \frac{\partial Error}{\partial b}$$

從錯誤中學習
== >誤差最小化

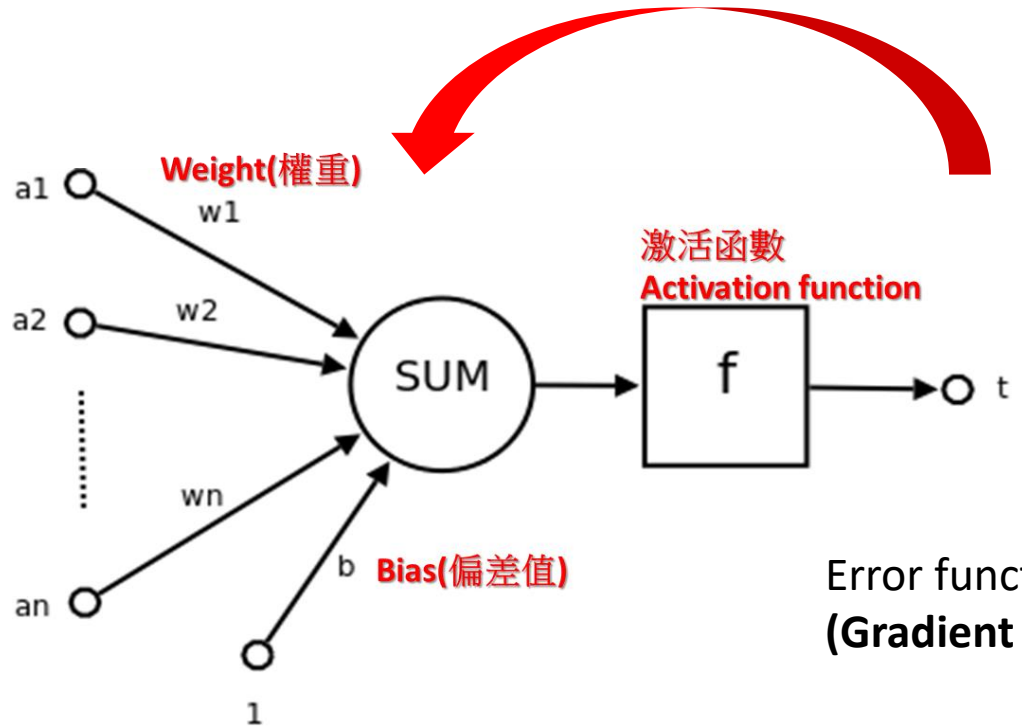

真實值
誤差(error)
預測值

誤差函數
(Error function)

Error function最小化 == >梯度下降法
(Gradient Descent)

具有學習能力的神經網路(4)

使用新的Weight(權重)與Bias(偏權值)
不斷計算直到誤差很小時結束
(需定義何時結束) (1)執行500回 或1000回....
(2)誤差小於0.00001

最後的W和b
就是學習到的參數

機器也能學習== >機器學習

誤差最小化

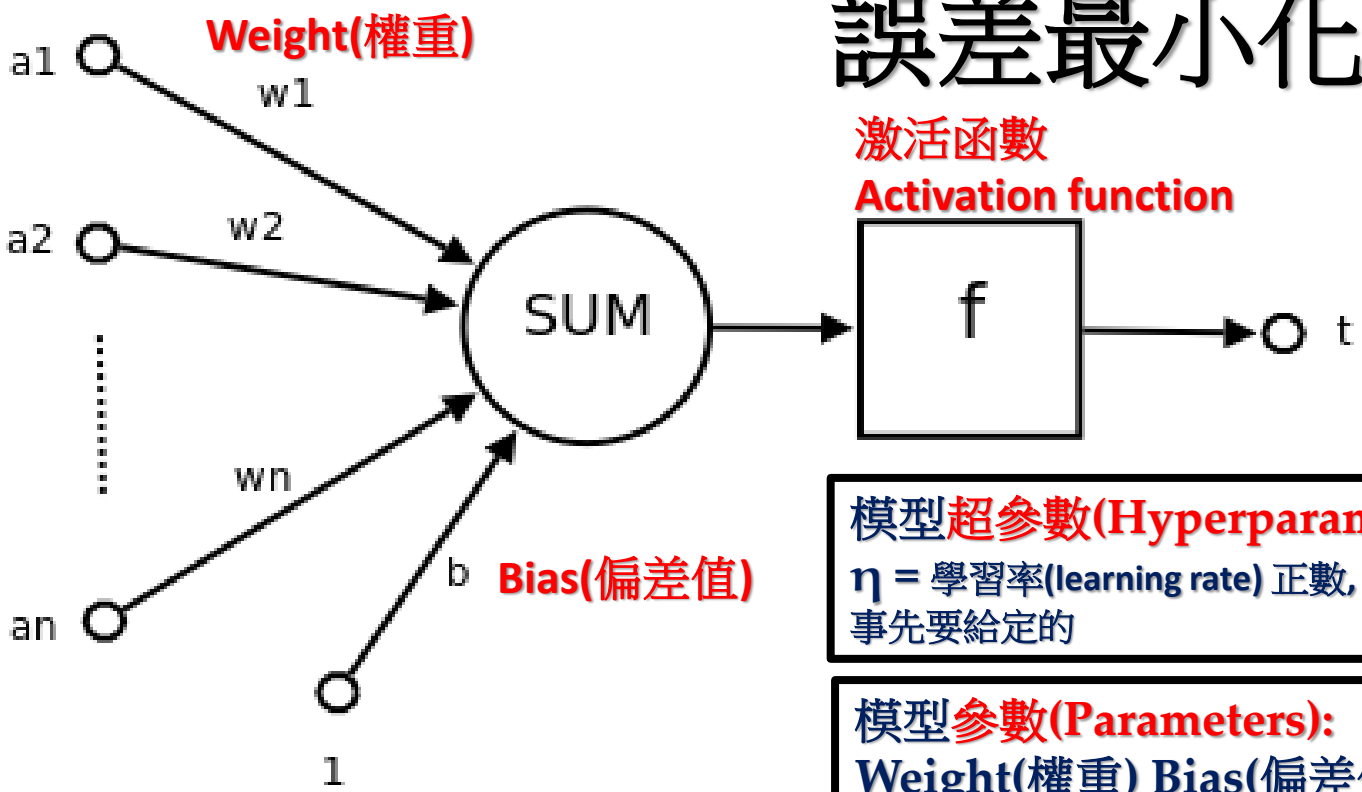

模型結果值

模型超參數(Hyperparameter):
η = 學習率(learning rate) 正數, 約取0.1~0.3
事先要給定的

模型參數(Parameters):
Weight(權重) Bias(偏差值)
模型學習到的結果

backpropagation(誤差)反向傳播

一個具有複雜且多層的MLP感知機,權重更新如何計算??

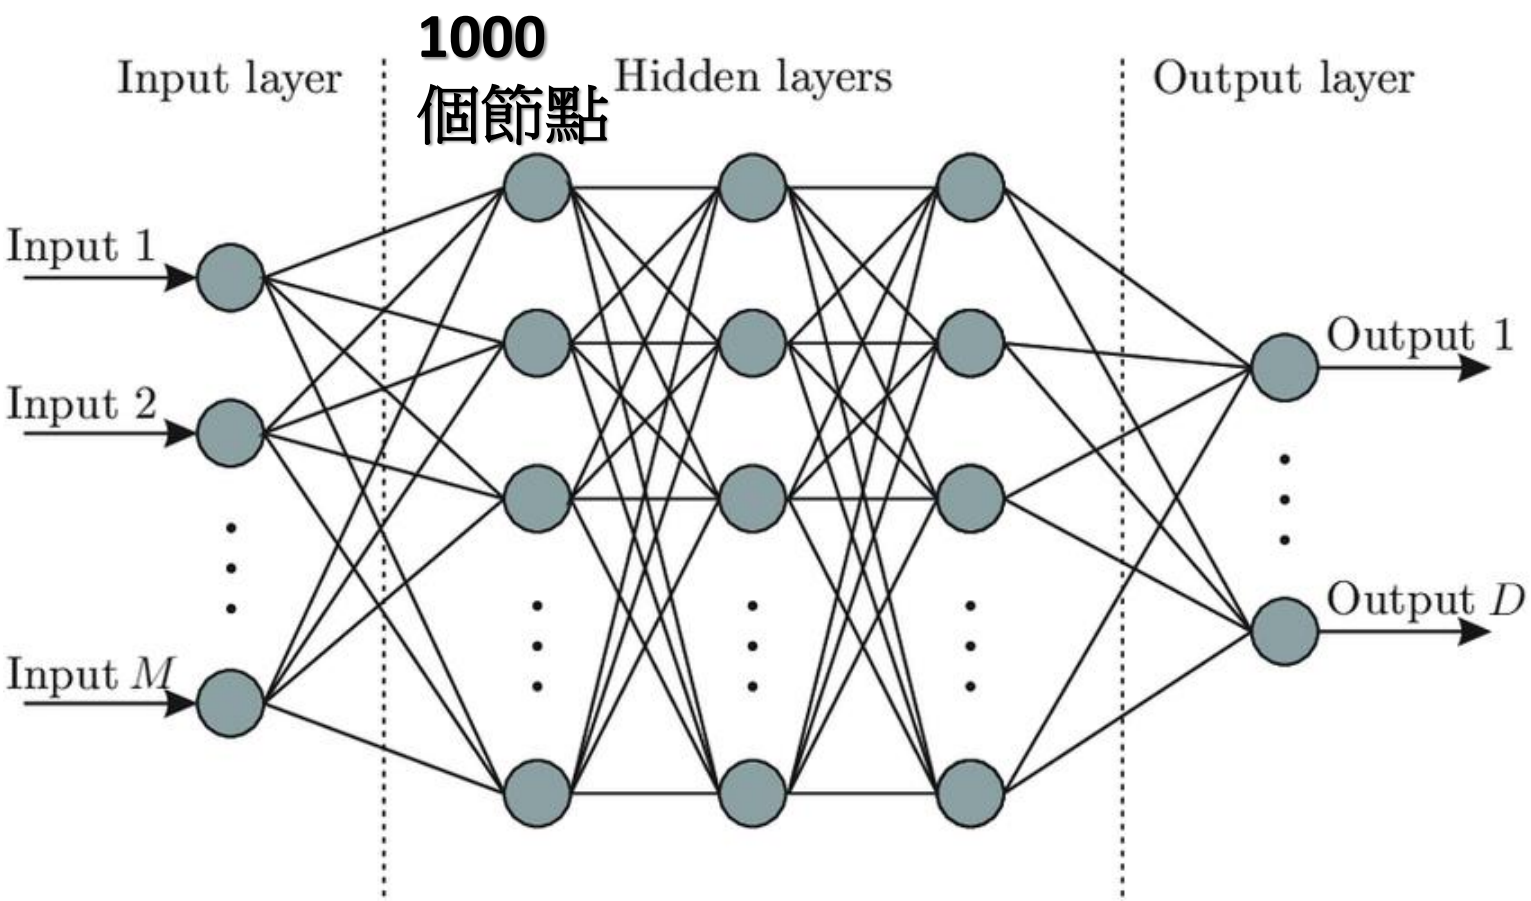

backpropagation(誤差)反向傳播

Forward propagation(正向傳播) **Feed Forward Network**

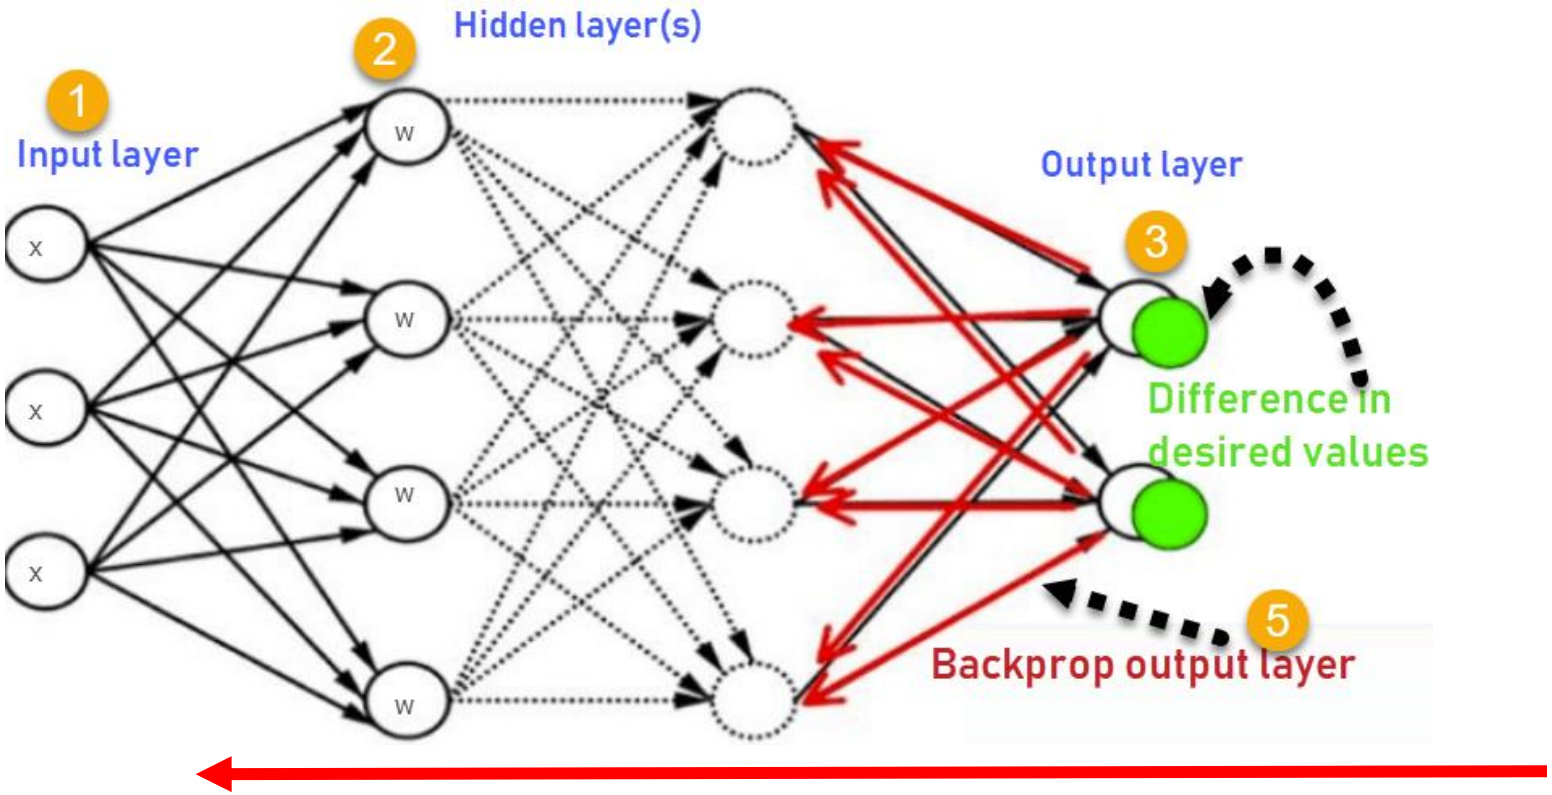

backpropagation(誤差)反向傳播

Rumelhart, David E.; Hinton, Geoffrey E.; Williams, Ronald J.
Learning representations by back-propagating errors.
Nature. 8 October 1986, 323 (6088): 533–536

Godfather of Deep Learning https://www.cs.toronto.edu/~hinton/

重要里程碑

1986 :the backpropagation algorithm for training multi-layer neural networks

Hinton, G. E., Osindero, S. and Teh, Y. (2006)
A fast learning algorithm for **deep** belief nets.
Neural Computation, 18, pp 1527-1554

2012 AlexNet (Alex Krizhevsky)啟動CNN電腦視覺熱潮

2018 Turing Prize (Yoshua Bengio and Yann LeCun)

2024 諾貝爾物理獎

https://en.wikipedia.org/wiki/Geoffrey_Hinton

2012年在coursera開設課程的簡報
https://www.cs.toronto.edu/~hinton/coursera_slides.html

Lecture 1b
What are neural networks?

2024 諾貝爾物理獎

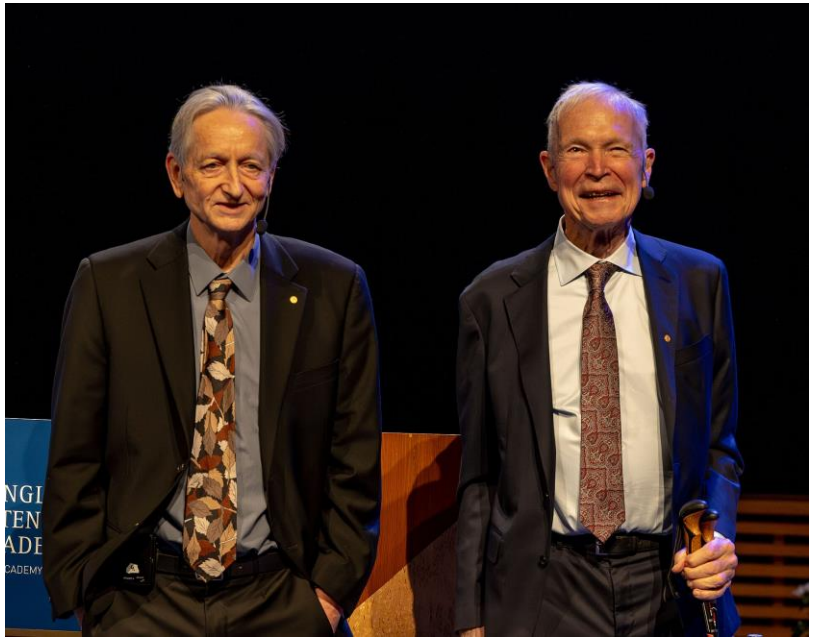

John J. Hopfield

Princeton University, NJ, USA

Hopfield neural network) 1982

Geoffrey Hinton

University of Toronto, Canada

玻爾茲曼機(Boltzmann machine) 1985

"for foundational discoveries and inventions that enable machine learning with artificial neural networks" 使機器學習能夠透過人工神經網路實現的基礎性發現和發明

They trained artificial neural networks using physics

J. J. Hopfield, "Neural networks and physical systems with emergent collective computational abilities", Proceedings of the National Academy of Sciences of the USA, vol. 79 no. 8 pp. 2554–2558, April 1982.

神經網路

機器學習

- 分類
- 迴歸

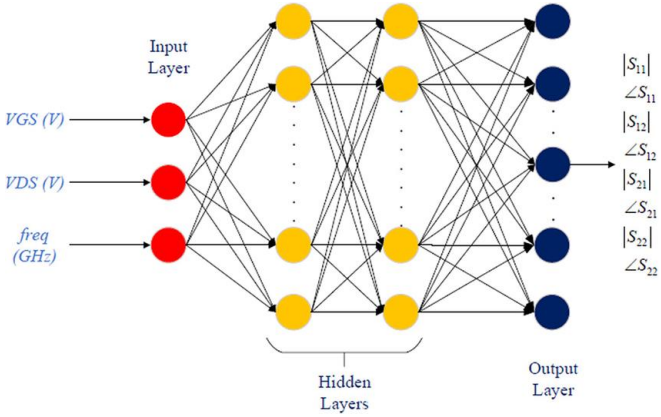

深度學習
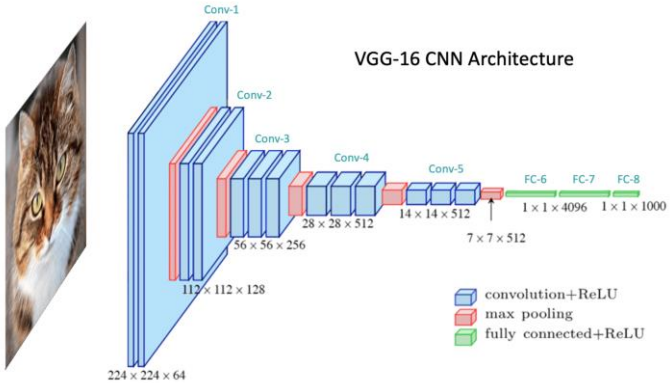
- **CNN** ⟷ 電腦視覺
- **RNN** ⟷ 自然語言處理
- **生成式AI**
  - VAE
  - GAN
  - Diffusion Model(擴散模型)
- **大語言模型(LLM)**
- **多模態大語言模型(MLLM)**
  Multimodal Large Language Model